

0_baseline 전략 — Ablation 실험 (발표용)

공통 규칙은 [strategy_common.md](#) 참조. 본 문서는 0_baseline 전용 사항만 명시.

1. 목적

발표/기록용 베이스라인 ablation. **계획했던 베이스라인 실험들을 깨끗하게 한 번 더 정리해 발표 자료 + 영구 기록 남기기.**

문제 의식:

- [optuna_merged.db](#)는 1차 실험 trial 모음이지만 (a) 계획했던 실험을 다 한 게 아님 (b) 변환된 환경에서 찍힌 값이라 절대값 의미 없고 참고용
- 한 study에 모든 축을 때려넣으면 TPE가 좋은 영역에 trial 몰아주므로 **조합 간 공정 비교 불가** (편향)

해결 방향: OAT(One-At-A-Time) + Group Study 2단계, 7+7 코어 병렬

2. 디렉토리 구조


```
3_modeling_신규/0_baseline/
├── strategy.md           # 이 문서
├── axes.py              # 축 정의 + reference + 그리드 생성 helper
├── 01_oat.ipynb         # OAT 노트북 (한 축씩 흔들기)
├── 02_group_study.ipynb # Group study 노트북 (Optuna multivariate)
└── 03_summary.ipynb    # 두 결과 종합 + 시각화 (발표 직전 1회)
```

산출물 위치:

```
4_output/experiments/2차_ablation/
├── oat/
│   ├── master.csv      # cell × seed × fold RMSE 영구 박제
│   ├── checkpoint.json # 진행 상황 (재실행 시 이어서)
│   └── plots/          # tornado.png 등
├── group/
│   ├── optuna.db       # study sqlite
│   ├── trials.csv      # trial 결과 export
│   └── plots/          # contour, importance.png 등
└── summary/
    ├── comparison.csv  # OAT marginal vs Group best 비교표
    └── summary_report.png # 발표용 종합 1장
```

3. 설계 — 2단계 병렬

3.1 전략 개요



3.2 두 노트북의 역할

	OAT (01)	Group study (02)
목적	축별 marginal 영향력 측정	축들 상호작용 + best 조합 탐색
방식	reference 1점에서 한 축씩 갈아끼움	11축 동시 샘플 (Optuna)
편향	없음 (모든 비교가 1:1)	있음 (TPE가 좋은 영역 집중) — but 여기선 의도된 편향
발표 용도	tornado plot ("이 축이 X 영향")	"최종 best 조합"
실패 보완	reference 의존 → best 조합 못 찾음	OAT가 marginal로 보완
결과 저장	csv	sqlite db

3.3 두 노트북의 일관성 (필수)

발표에서 두 결과를 나란히 보이려면 환경이 같아야 함:

- 데이터 **split**: 같은 5-fold (KFold seed=42, unit-level — strategy_common §6)
- PP: 동일 PP_FIXED (strategy_common §1)
- 모델 **HP**: LGBM default 고정 (HPO 없음 — 축 효과만 분리하기 위해)
- **reference 1점**: OAT의 reference = Group study의 anchor (동일 영점)
- **axes.py**에서 단일 정의: 두 노트북이 import → 축 변경 시 1군데 수정

4. OAT 설계 (01_oat.ipynb)

4.1 Reference 1점

[experiment_status_summary.xlsx](#) 60 cell 중 val_rmse 최소(0.001141):

```

REFERENCE = {
    'run_clf':      False,
    'reg_level':    'position',
  
```

```

'TARGET_TRANSFORM': 'yeo-johnson',
'CLIP_Y_EXTREME': True,
'loss': 'mse', # LGBM default
'impute': 'spatial', # PP_FIXED 기준
'outlier': 'winsorize',
'scaling': 'robust',
'agg': 'mean',
'path': 'agg_then_reg',
}

```

4.2 혼들 11축

#	축	옵션	출처	비고
1	CLF	off / proba / proba+filter / binary	xlsx	run_clf×clf_output×clf_filter 통 합
2	reg_level	position / unit	xlsx	
3	TARGET_TRANSFORM	none / log1p / yeo- johnson / sqrt	xlsx + sqrt 추가	
4	CLIP_Y_EXTREME	True / False	xlsx	
5	loss	mse / huber / poisson / tweedie	신규	LGBM objective
6	impute	none / median / spatial / knn	신규	NaN→ 처리
7	outlier	none / winsorize / iqr_clip	신규	die-level
8	scaling	none / robust / standard / quantile	신규	트리니까 효과 미미 예상 — 그게 결과
9	agg	mean / median / max / min / Q75	신규	die→unit 함수
10	path	agg_then_reg / reg_then_agg	신규	사용자 의견 "분류부터 집계로"
11	seed	5개 (42, 7, 123, 2024, 31415)	—	모든 셀에 5 seed

4.3 Cell 수 계산

각 축 옵션 중 reference 값과 다른 것만 변형 cell:

- $(4-1) + (2-1) + (4-1) + (2-1) + (4-1) + (4-1) + (3-1) + (4-1) + (5-1) + (2-1) = 24 \text{ 변형 cell} + \text{reference } 1 = 25 \text{ cell}$

× 5 seed = **125 cell-seed** × 5 fold = **625 fit**

LGBM default + position pivot (unit 약 26K) → fit당 3~5분 가정 → **31~52시간 ≈ 1.5~2일**.

4.4 출력 — master.csv

row 단위 영구 삭제. 발표 시 csv 로딩 → tornado plot 즉시 생성.

컬럼	예시
axis	TARGET_TRANSFORM
option	log1p
seed	42
fold	0
val_rmse	0.005442
is_reference	False
elapsed_sec	187.3
timestamp	2026-05-08T14:23:01

`is_reference=True`인 행이 1개 (모든 축의 reference 옵션과 같은 셀).

4.5 Checkpoint — 끊겨도 이어서

`checkpoint.json`에 완료한 (axis, option, seed) 튜플 기록. 재실행 시 master.csv에 이미 있으면 skip.

```
done = set(zip(master.axis, master.option, master.seed))
for cell in oat_grid:
    if cell.tuple in done: continue
    ...
```

5. Group Study 설계 (02_group_study.ipynb)

5.1 Search space — OAT의 11축 그대로

axes.py의 `AXES` dict를 그대로 Optuna `suggest_categorical`로 변환:

```
def objective(trial):
    cfg = {
        axis: trial.suggest_categorical(axis, options)
        for axis, options in AXES.items()
        if axis != 'seed' # seed는 고정 (재현성)
    }
    return run_one(cfg, seed=42) # 5-fold mean RMSE
```

LGBM HP는 default 고정. **축 11개만 흔들** (HP 같이 흔들면 축 효과와 섞여 발표 일관성 깨짐).

5.2 Sampler

[strategy_common.md §4](#) 권장:

```
TPESampler(
    seed=None,          # 다양성
    multivariate=True,  # ★ 축들의 결합 분포 학습 = 상호작용
    group=True,         # 자연 블록 (예: clf=False면 clf_output, clf_filter 무관)
)
```

5.3 Pruner

LGBM default fit + 5-fold라 fold별 중간값 잘 안 나옴. **MedianPruner**는 비활성화 (5 fold 다 끝나야 점수 나옴).

5.4 Trial 예산

- 11축 카르테시안 = $4 \times 2 \times 4 \times 2 \times 4 \times 4 \times 3 \times 4 \times 5 \times 2 \approx 122,880$ 조합
- 모두 못 보니까 TPE로 좋은 영역 학습 → 충분 trial 수 = ?

trial	fit	예상 시간 (5-fold, fit당 ~4분)	발표 적합성
200	1,000	~67h ≈ 3일	최소 권장
300	1,500	~100h ≈ 4일	권장
500	2,500	~167h ≈ 7일	시간 빡빡

default = 300 trial (사용자 결정 사항).

5.5 Optuna 산출물

- `optuna.db` — sqlite study (그대로 보존)
- `trials.csv` — `study.trials_dataframe()` export (master.csv와 같은 형식으로 변환 가능)
- `param_importance.csv` — `optuna.importance.get_param_importances()` (OAT tornado와 비교 가능)

6. 7+7 병렬 운용 — N_JOBS 설정

[strategy_common.md §8](#) 14 코어 기준.

```
# 두 노트북 상단 동일하게
N_JOBS = 7
```

- `LGBMRegressor(n_jobs=N_JOBS)` — 모델 내부 병렬
- `study.optimize(..., n_jobs=1)` — Optuna trial 직렬 (모델 내부와 곱셈 효과 방지)
- OAT 노트북도 `for cell in grid:` 직렬 (모델 내부 N_JOBS만 활용)

시작 순서:

1. 슬롯 B (Group study) 먼저 시작 — TPE가 학습할 시간 필요
2. 슬롯 A (OAT) 동시 시작 — 시간 짧음

메모리: LGBM 1 fit $\approx$ 4~8GB. 두 노트북 동시 = 8~16GB. 학원 환경 RAM 확인 필요.

7. axes.py — 두 노트북 공통 모듈

```
# 3_modeling_신규/0_baseline/axes.py

REFERENCE = { ... } # §4.1

AXES = {
    'CLF': ['off', 'proba', 'proba+filter', 'binary'],
    'reg_level': ['position', 'unit'],
    'TARGET_TRANSFORM': ['none', 'log1p', 'yeo-johnson', 'sqrt'],
    'CLIP_Y_EXTREME': [True, False],
    'loss': ['mse', 'huber', 'poisson', 'tweedie'],
    'impute': ['none', 'median', 'spatial', 'knn'],
    'outlier': ['none', 'winsorize', 'iqr_clip'],
    'scaling': ['none', 'robust', 'standard', 'quantile'],
    'agg': ['mean', 'median', 'max', 'min', 'Q75'],
    'path': ['agg_then_reg', 'reg_then_agg'],
}

SEEDS = [42, 7, 123, 2024, 31415]

def generate_oat_grid():
    """OAT cell list 생성. reference 1개 + 각 축의 non-reference 옵션."""
    grid = [(REFERENCE.copy(), seed) for seed in SEEDS] # reference x 5 seed
    for axis, options in AXES.items():
        ref_val = REFERENCE[axis]
        for opt in options:
            if opt == ref_val: continue
            cfg = REFERENCE.copy()
            cfg[axis] = opt
            for seed in SEEDS:
                grid.append((cfg, seed))
    return grid

def run_one(cfg: dict, seed: int) -> dict:
    """단일 cell 학습 + 5-fold val RMSE 반환."""
    # 1) cfg에 따라 PP 적용
    # 2) cfg에 따라 모델 학습
    # 3) 5-fold val RMSE 평균 반환
    ...
```

핵심: **run_one**이 두 노트북 공통 **entrypoint**. OAT는 grid 순회, Group study는 Optuna가 호출.

8. 03_summary.ipynb — 시각화

발표 직전 1회 실행. master.csv + optuna.db 읽어 종합:

8.1 OAT — Tornado plot

축별 RMSE range (max - min) 정렬, 가로 bar:

```
TARGET_TRANSFORM ██████████ Δ 0.0044
CLF ████████ Δ 0.0008
loss ████████ Δ 0.0004
CLIP ████████ Δ 0.0001
scaling . Δ 0.0000
...
```

8.2 Group study — Param importance

`optuna.importance.get_param_importances()` 막대 그래프. OAT tornado와 나란히 비교 → "marginal과 multivariate가 일치하면 신뢰성 ↑".

8.3 비교표 (comparison.csv)

axis	OAT marginal best	Group study best	일치?
TARGET_TRANSFORM	yeo-johnson	yeo-johnson	O
CLF	off	off	O
...	...	...	...

8.4 출력

- `summary/tornado.png` — OAT
- `summary/group_importance.png` — Group study
- `summary/comparison.csv` — 표
- `summary/summary_report.png` — 위 3개 합본 1장 (발표용)

9. 발표 스토리

"우리는 베이스라인 단계에서 11개 축의 효과를 측정했다."

1) OAT (편향 없는 marginal):

- 25 cell × 5 seed = 125 fit
- tornado plot: TARGET_TRANSFORM이 가장 큰 축 (Δ 0.0044)
- scaling은 거의 무영향 (트리 모델이라 예상대로)

2) Group study (상호작용 포함):

- 300 Optuna trial, multivariate TPE

- best 조합: target=yeo-johnson + clip=True + clf=off + ...
- param importance ranking이 OAT tornado와 일치
- 상호작용 효과 작음 = OAT marginal이 충분 신뢰 가능

3) 결론: 11개 축 중 4개가 RMSE 좌우.

나머지 7개는 default 그대로 가도 안전 → 모델링 단계로 진입할 때 탐색 공간을 4축으로 좁혀 효율화."

10. 노트북 작성 규칙

[strategy_common.md §14](#) 준수.

특히 0_baseline은 **공정 비교가 목적**이라:

- LGBM HP는 default 고정 (HPO 안 함)
- PP는 PP_FIXED 고정 (단, axes.py의 impute/outlier/scaling 축으로 흔드는 셀은 그 축만 변형)
- 후처리 (zero_clip, position weight 등) **모두 비적용** — 축 효과만 분리

11. 결정 필요 사항

#	사항	제안 default	결정 시점
1	Group study trial 수	300	노트북 작성 전
2	OAT 11축 그대로? 추가/제거?	그대로	노트북 작성 전
3	seed 5개 (42, 7, 123, 2024, 31415) OK?	OK	노트북 작성 전
4	출력 위치 4_output/experiments/2차_ablation/ OK?	OK	노트북 작성 전
5	path='reg_then_agg'의 가중치 정책	균등 0.25×4	OAT 단계 — 가중치 탐색은 3차 funnel
6	LGBM default HP — n_estimators 명시	100 (sklearn default)	노트북 작성 전

12. 검증 근거

- **편향 우려**: TPE는 좋은 영역에 trial 몰아주므로 한 study 다축 학습 시 조합 간 trial 수 불균형 → 비교 불가. OAT는 reference 1점에서 1:1 비교라 편향 없음
- **OAT 한계 (상호작용)**: xlsx 데이터에서 CLIP 효과가 TARGET에 따라 큰 차이 (yeo-johnson + CLIP=F: $\Delta +0.00001$ vs none + CLIP=F: $\Delta +0.00273$) → OAT만으로는 못 잡음 → Group study로 보완
- **공정 비교 핵심**: 같은 5-fold split + 같은 PP + 같은 LGBM default HP로만 축 효과 분리 가능. axes.py의 `run_one()`이 단일 entrypoint
- **재현성**: master.csv에 모든 fit row 박제 → 발표 자료 png는 매번 csv에서 즉석 생성. 다음에 축 추가해도 csv 합치면 됨

13. 실행 순서

1. 사용자 §11 결정 사항 확인
2. axes.py 작성 (run_one 포함)
3. 02_group_study.ipynb 시작 (코어 7) — 먼저 시작 (시간 김)
4. 01_oat.ipynb 시작 (코어 7) — 동시
5. 둘 다 끝나면 03_summary.ipynb 1회 실행 → 발표 자료